Alma Mater Studiorum — Università di Bologna
Campus di Cesena

Dipartimento di Informatica — Scienza e Ingegneria
Corso di Laurea magistrale in Ingegneria e Scienze Informatiche

Stima dei costi database non relazionali

Calcolo e stima dei costi di elaborazione di diverse query su attributi indicizzati
Databse non relazionali in questione MongoDb e CouchDB

Presentata da:
Matteo Santoro
Matricola 0000881608

Relatore:
Prof. Alessandra Lumini

Correlatore:
Prof. Alessandra Lumini

III sessione di laurea
Anno Accademico 2022–2023

Parole chiave

Parola chiave 1

Parola chiave 2

Dedica

Sommario

I database sono diventati una parte importante del quotidiano, ogni tipo di applicazione o software che siamo abituati ad utilizzare ha l'esigenza di prendere, processare e conservare diversi tipi di dati, e' quindi fondamentale poter ottimizzare al meglio queste operazioni, all'interno della tesi che presentero' andro' ad analizzare e stimare alcuni possibili metodi e condurre un'analisi comparativa anche attraverso diversi sistemi di database. Io e la Prof.ssa Lumini abbiamo deciso di utlizzare due database Document-Based non relazionali, MongoDB e CouchDB ed un database di tipo relazionale, Oracle. La finalita' di questa tesi e' arrivare a valutare il miglior piano d'accesso possibile e la modellazione dei dati piu' efficente.

Indice

Introduzione

1 Differenze tra relational/non-relational DB

Lorem ipsum dolor sit amet, consectetur adipiscing elit. Suspendisse et ex vehicula, interdum mi eu, auctor augue. Suspendisse vel sagittis urna. In vitae ligula ipsum. Vivamus mattis neque efficitur, gravida purus facilisis, rhoncus felis. Class aptent taciti sociosqu ad litora torquent per conubia nostra, per inceptos himenaeos. Nunc bibendum urna porta quam congue ornare. Fusce eget consequat libero. Donec varius justo vel libero malesuada, sit amet dignissim ex tincidunt. In pharetra vestibulum lacus quis laoreet. Donec vel laoreet ex, sed facilisis massa. Mauris commodo velit est. Maecenas non sem elementum, faucibus velit et, bibendum mi. Integer laoreet ex et eros accumsan, nec dapibus nisi vestibulum. Donec sed nunc quis mi gravida congue non vel tortor. Interdum et malesuada fames ac ante ipsum primis in faucibus.

Nullam non pharetra arcu. Donec eget velit elit. Pellentesque sed tortor sodales neque tristique rutrum. Vivamus et ex dolor. Vestibulum lacinia augue sit amet libero mattis pellentesque. In sed congue ante, quis tempus neque. Vestibulum semper eu sapien et vestibulum.

In ac erat ullamcorper, ultricies dolor sit amet, tempus neque. Pellentesque quam erat, ornare ac justo at, cursus luctus ex. Pellentesque at turpis blandit, elementum ex ac, fringilla nibh. Etiam et tincidunt lacus. Integer mattis mi sit amet faucibus rutrum. Sed at nisi commodo, ultricies purus a, tempus lacus. Mauris accumsan enim nisi, in tempor velit pharetra eu. Sed eu turpis et ante sagittis sodales. Duis a tellus id risus ultricies accumsan. Vestibulum bibendum in sapien sit amet rhoncus. Fusce aliquam, metus vel efficitur pulvinar, nibh lacus ultricies nisl, nec rhoncus elit ligula vitae risus. Mauris bibendum eget erat non rutrum. Curabitur in ligula eget lectus facilisis molestie sed sed neque. Vestibulum eu faucibus augue, a luctus augue. Nam lobortis massa non lorem condimentum vehicula. Aliquam efficitur cursus neque, efficitur placerat libero tincidunt non. Nullam.

2 Il nostro caso di studio

Durante la progettazione si e' deciso di utilizzare una relazione per poter testare i diversi metodi di collezione dei dati. La relazione e' formata da 2 entita' A e B,in un esempio di

un social network l'entita' A sono i Post e l'entita' B i Commenti sotto ogni post, collegate da una relazione 1..N -> 1...1, per ogni A esistono 10 B relativi, ogni Post contiene 10 Commenti.

La modellazione delle entita' e' stata fatta creando 2 triplette di attributi uguali, sulla seconda tripletta al contrario della prima sono stati costruiti degli indici su ogni attributo, questi attributi generici hanno una propria selettivita':

$$\left.\begin{aligned} sel(Att1, Att4) &= \frac{1}{10} \\ sel(Att2, Att5) &= \frac{1}{10.000} \\ sel(Att2, Att6) &= \frac{1}{100} \end{aligned}\right\}$$

Poi un attributo testaule, A7, di 100 bytes per poter inserire descrizione.

Il numero di Entita' A e' di 10^5 e di conseguenza ci sono 10^6 entita' B.

A (POST)


```
"_id": 6808,
"AK": 6808,
"A1": 3042,
"A2": 300,
"A3": 8,
"A4": 3042,
"A5": 300,
"A6": 8,
"A7": "Lorem ipsum dolor sit amet, consectetur adipiscing elit.
  Fusce lacinia eget arcu et maximus. Ut tempus est sit amet
  tortor commodo, sit amet facilisis mi rhoncus. Donec et elit
  venenatis, consequat tellus eu, tristique orci. Duis
  tristique sem ut nulla ullamcorper, a porta risus efficitur.
  Cras sed neque et nisl tincidunt vestibulum. Phasellus
  tristique tempor facilisis. Sed facilisis lectus eros, sed
  aliquet lacus elementum sed. Integer vel dictum mi.
  Maecenas pharetra tempus eros, efficitur mattis erat cursus
  in. Nulla sit amet quam velit. Nullam tempus dictum lacus
  id porttitor. Vestibulum facilisis pulvinar fermentum.
  Ut elementum maximus feugiat. In at mollis leo, eu
  facilisis magna. Vestibulum sed nisi ultricies, tincidunt
  enim ac, fringilla ex. Phasellus pharetra mollis nisi
  a fermentum. In nec faucibus nulla, eget molestie magna.
  Vivamus in gravida ex. Aenean scelerisque gravida
```

ipsum, nec congue enim posuere sit amet. Donec vitae felis
id sem congue blandit eget non justo quis."

A (POST)

B (COMMENTI)


```
"_id": 73888,
"BK": 738878,
"F_AK": 70394,
"B1": 94207,
"B2": 176,
"B3": 3,
"B4": 94207,
"B5": 176,
"B6": 3,
"B7": "Lorem ipsum dolor sit amet, consectetur adipiscing elit.
  Fusce lacinia eget arcu et maximus. Ut tempus est sit amet
  tortor commodo, sit amet facilisis mi rhoncus. Donec et elit
  venenatis, consequat tellus eu, tristique orci. Duis
  tristique sem ut nulla ullamcorper, a porta risus efficitur.
  Cras sed neque et nisl tincidunt vestibulum. Phasellus
  tristique tempor facilisis. Sed facilisis lectus eros, sed
  aliquet lacus elementum sed. Integer vel dictum mi.
  Maecenas pharetra tempus eros, efficitur mattis erat cursus
  in. Nulla sit amet quam velit. Nullam tempus dictum lacus
  id porttitor. Vestibulum facilisis pulvinar fermentum.
  Ut elementum maximus feugiat. In at mollis leo, eu
  facilisis magna. Vestibulum sed nisi ultricies, tincidunt
  enim ac, fringilla ex. Phasellus pharetra mollis nisi
  a fermentum. In nec faucibus nulla, eget molestie magna.
  Vivamus in gravida ex. Aenean scelerisque gravida
  ipsum, nec congue enim posuere sit amet. Donec vitae felis
  id sem congue blandit eget non justo quis."
```


B (COMMENTI)

!!!!!!!!! LE FOTO NON VANNO BENE, LE CHIAVI DEVONO ESSERE SEGNALATE !!!!!!!!!!!!!!!!!!!!!!!!

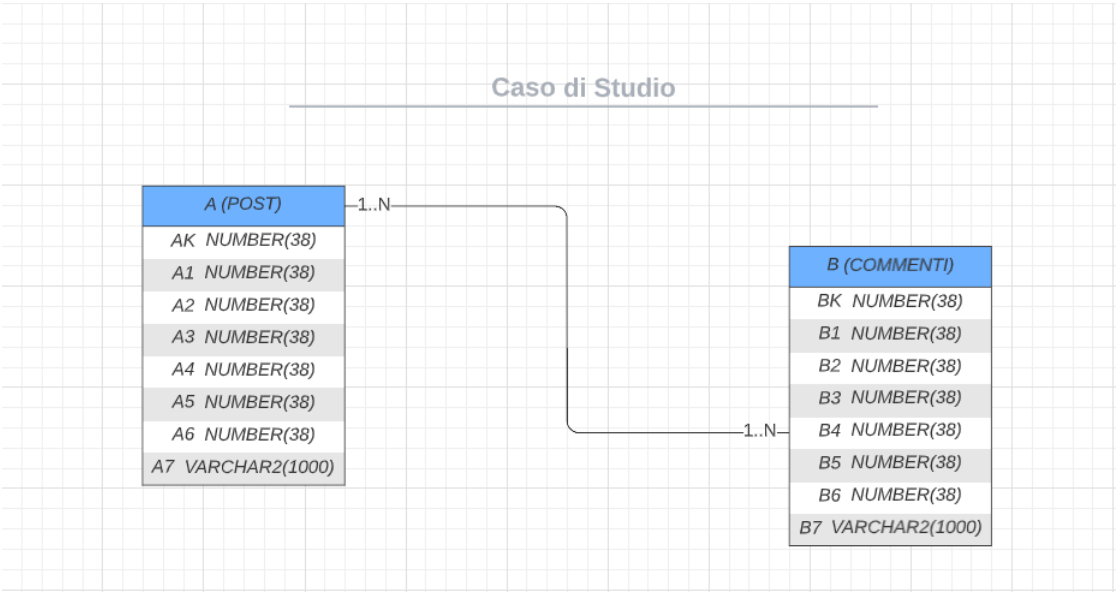

3 Modellazione dei dati

La modellazione dei dati ha un ruolo fondamentale nel calcolo dei costi di accesso e quindi costi di esecuzione delle query, le soluzioni dalle quali si e' deciso di di partire sono quelle dell'Embedding e del Referencing. Utilizzando un sistema non relazionale abbiamo necessita' di esprimere la relazione tra A e B in un modo differente, attraverso il referencing colleghiamo le un entita' inserendo un riferimento della seconda e viceversa, per poter poi eseguire ad esempio query di join o voler recuperare tutti i dati dell'entita' referenziata c'e' il bisogno di mantenere all'interno del database la collezione contenente i rimanenti attributi. Es. nell'eventuale soluzione del referencing di B all'interno di A, ci sono due collezioni ossia A con la foreign key relativa (BK) relativa a B e l'intera collezione B.

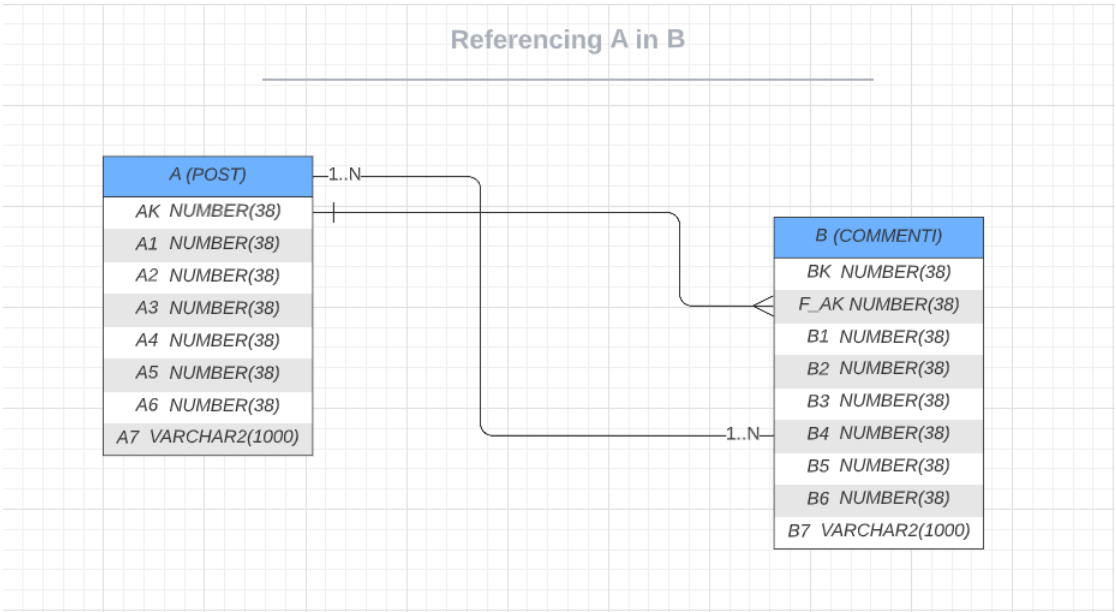

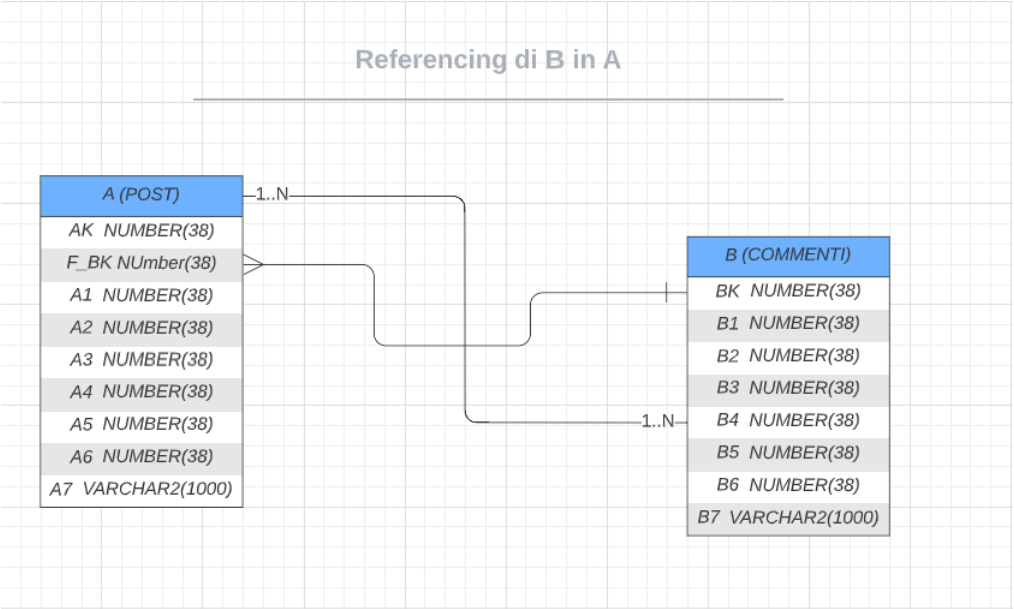

La soluzione embedding consiste nel creare un'unica collezione di documenti che racchiudono al loro interno sia documenti di A che documenti di B.

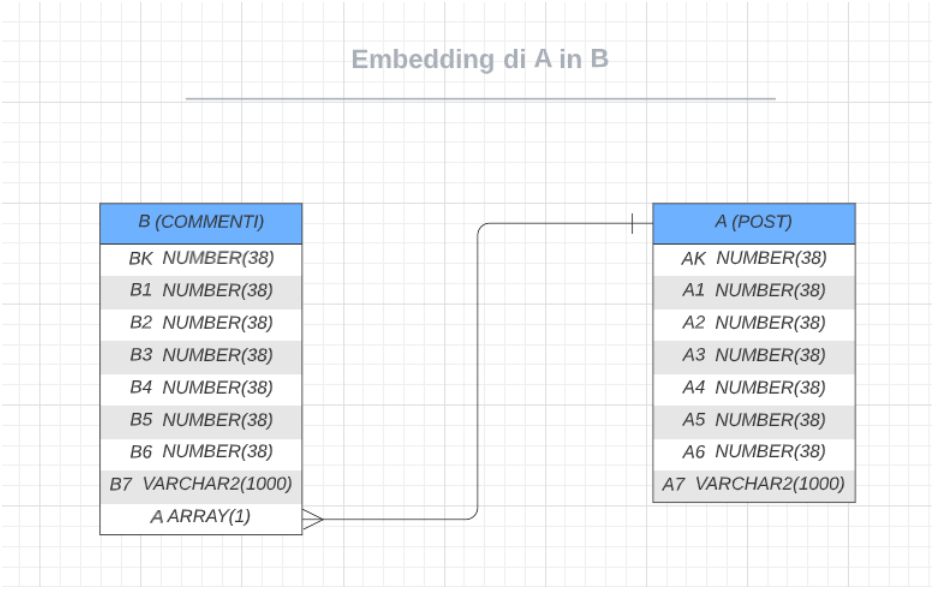

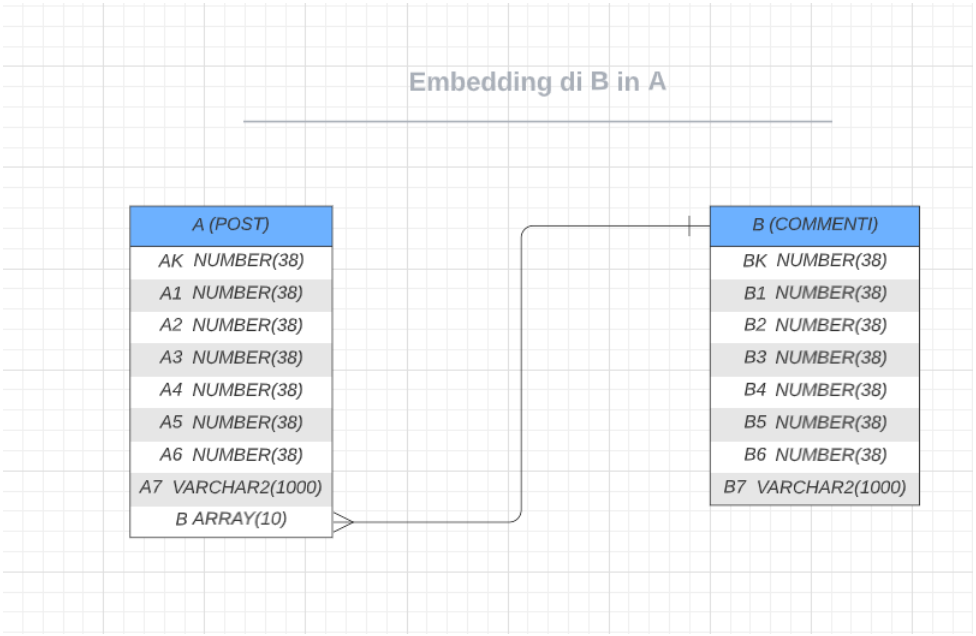
Embedding di B in A
A (POST)
AK NUMBER(38)
A1 NUMBER(38)
A2 NUMBER(38)
A3 NUMBER(38)
A4 NUMBER(38)
A5 NUMBER(38)
A6 NUMBER(38)
A7 VARCHAR2(1000)
B ARRAY(10)
B (COMMENTI)
BK NUMBER(38)
B1 NUMBER(38)
B2 NUMBER(38)
B3 NUMBER(38)
B4 NUMBER(38)
B5 NUMBER(38)
B6 NUMBER(38)
B7 VARCHAR2(1000)

Costi

1 Calcolo dei costi

La parte teorica di questo progetto si basa sulla stima di costi di esecuzione delle operazioni sulle differenti opzioni di organizzazione dei documenti, per calcolare cio' abbiamo bisogno di alcune formule che andro qui ad elencare:

1.1 NL

$$NL = \left\lfloor \frac{NK * len(k) + NR * len(p)}{D * u} \right\rfloor$$

1.2 g

$$g = \left\lceil \frac{D - len(p)}{2 * (len(k) + len(p))} \right\rceil$$

1.3 h

Il calcolo per l'altezza del b-tree relativo agli indici degli attributi verrebbe normalmente calcolato attraverso questa formula, nel nostro caso di studio l'altezza e' stata approssimata a 3.

$$\left\lfloor \log_{(2*g+1)} NL \right\rfloor \leq h \leq \left\lceil \log_{(g+1)} \frac{NL}{2} \right\rceil$$

1.4 NP

$$NP = \left\lfloor \frac{NR * len(t)}{D * u} \right\rfloor$$

1.5 Costo del nested loop

In cui ho R relazione esterna e S relazione interna

- senza predicato di selezione

$$NP_R + NR_R * NP_S$$

- con predicato di selezione

$$NP_R + (sel(pred) * NR_R) * costo(S)$$

1.6 Indice clustered

$$Costo(S) = (h-1) + \left\lfloor \frac{1}{NK} * NL \right\rfloor + \lfloor sel(pred) * NP \rfloor$$

1.7 Indice unclustered

$$Costo(S) = (h-1) + \left\lfloor \frac{1}{NK} * NL \right\rfloor + 1 + \phi(\frac{NR}{NK}, NP)$$

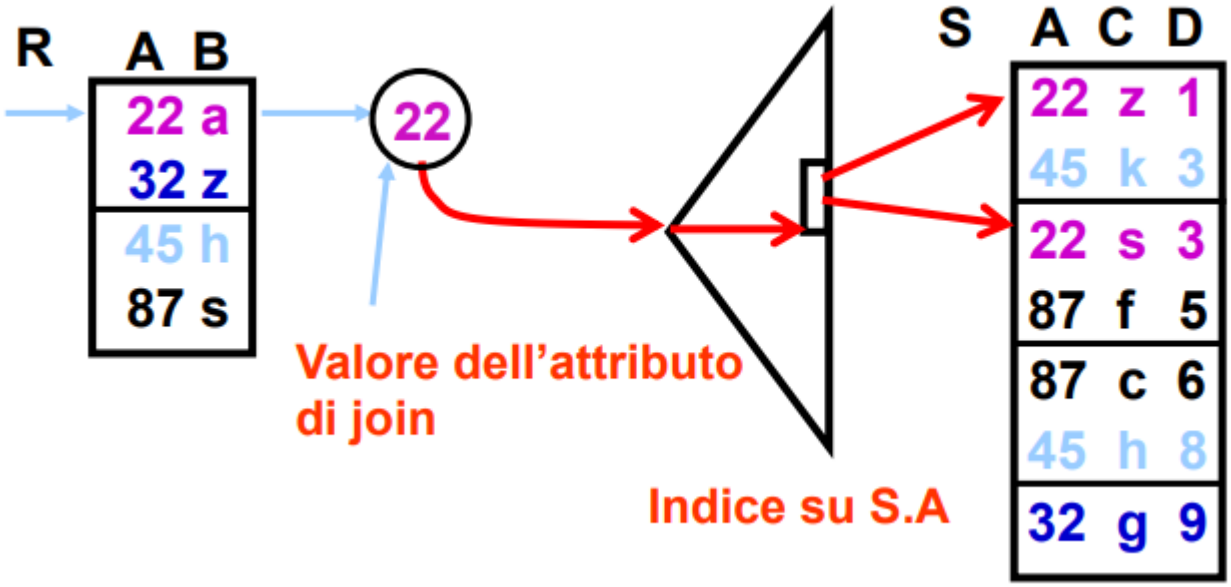

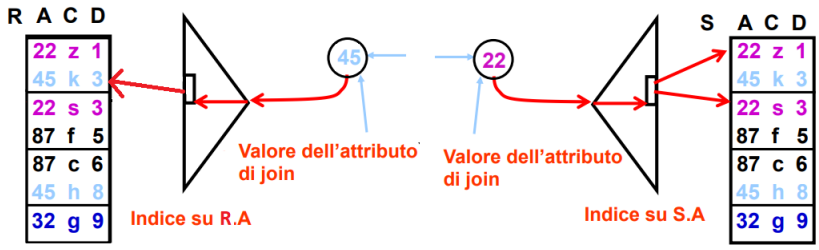
R A C D
22 z 1
45 k 3
22 s 3
87 f 5
87 c 6
45 h 8
32 g 9
45
Valore dell'attributo di join
Indice su R.A
22
Valore dell'attributo di join
Indice su S.A
S A C D
22 z 1
45 k 3
22 s 3
87 f 5
87 c 6
45 h 8
32 g 9

MongoDb

1 Caratteristiche

MongoDb e' uno dei piu' diffusi database non relazionali orientato ai documenti, di tipo NoSQL, utilizza documenti in un formato JSON al posto delle tipiche tabelle dei sistemi relazionali. Piu' precisamente MongoDb utilizza i BSON ossia JSON binari per rappresentare strutture dati semplici e array associativi (oggetti in MongoDb), un BSON contiene una lista ordinata di elementi appartenenti ai seguenti tipi:

- stringhe
- interi (32 o 64 bit)
- double (numeri a virgola mobile a 64 bit, standard IEEE 754)
- date (numeri interi in millisecondi dal'epoca Unix come riferimento, 1º gennaio 1970)
- byte array (dati binari)
- booleani (true e false)
- NULL
- oggetto BSON
- array BSON
- espressioni regolari
- codice JavaScript

2 Organizzazione dei dati

2.1 Creazione collezioni

Per poter originare i set di dati sui quali lavoriamo si e' partiti da 2 enormi file JSON generati al paragrafo ??????????? //TODO riguarda qua // contenenti POST (A) e COMMENTI(B). Il paramentro $out posto dopo la query ha creato una collezione a tutti gli effetti sulla quale poter eseguire le query all'interno della rete del container.

Referencing

Il referencing di A in B si ottiene facilmente proiettando gli attributi della collezione B, dato che contiene al suo interno la foreign Key di A.

Referencing di A in B

```
db.B.aggregate([
  {
    $project: {
      "_id" : "$BK",
      "BK" : "$BK",
      "AK" : "$FAK",
      "B1" : "$B1",
      "B2" : "$B2",
      "B3" : "$B3",
      "B4" : "$B4",
      "B5" : "$B5",
      "B6" : "$B6",
      "B7" : "$B7"
    }
  },{
  $out : "referencing_A_in_B"
}
])
```

Referencing di A in B


```
"_id": 21748,
"BK": 21748,
"AK": 70394,
"B1": 85337,
"B2": 255,
"B3": 6,
"B4": 85337,
"B5": 255,
"B6": 6,
"B7": "Lorem ipsum dolor sit amet, consectetur adipiscing elit.
  Fusce lacinia eget arcu et maximus. Ut tempus est sit amet
  tortor commodo, sit amet facilisis mi rhoncus. Donec et elit
  venenatis, consequat tellus eu, tristique orci. Duis
  tristique sem ut nulla ullamcorper, a porta risus efficitur.
```

```
Cras sed neque et nisl tincidunt vestibulum. Phasellus
tristique tempor facilisis. Sed facilisis lectus eros, sed
aliquet lacus elementum sed. Integer vel dictum mi.
Maecenas pharetra tempus eros, efficitur mattis erat cursus
in. Nulla sit amet quam velit. Nullam tempus dictum lacus
id porttitor. Vestibulum facilisis pulvinar fermentum.
Ut elementum maximus feugiat. In at mollis leo, eu
facilisis magna. Vestibulum sed nisi ultricies, tincidunt
enim ac, fringilla ex. Phasellus pharetra mollis nisi
a fermentum. In nec faucibus nulla, eget molestie magna.
Vivamus in gravida ex. Aenean scelerisque gravida
ipsum, nec congue enim posuere sit amet. Donec vitae felis
id sem congue blandit eget non justo quis."
```

Referencing di A in B

Il referencing di B in A invece richiede un join, un' operazione piu' onerosa per la quale si e' dovuto passare il parametro allowDiskUse=true per poter utilizzare a pieno la memoria della macchina e quindi eseguire il join. Trovando di fatto le chiavi e aggiungendole all'array B che arrivera' a contenere 10 chivi BK per ogni AK dato che il rapporto e' di 1:10.

Referencing di B in A

```
db.B.aggregate(
[
   {
      $group: {
        _id: {"AK" : "$FAK"}, "BK": {$addToSet : "$BK"}
      }
    },
    {
      $lookup: {
        from: 'Ap',
        localField: '_id.AK',
        foreignField: 'AK',
        as: 'AK'
      }
    },{
      $project : {"_id" : 0,"BK.FAK" : 0}
    },{
```

```
    $unwind: {
      path: "$AK",
    }},{
      $project : {
      "_id" : "$AK.AK",
      "AK" : "$AK.AK",
      "A1" : "$AK.A1",
      "A2" : "$AK.A2",
      "A3" : "$AK.A3",
      "A4" : "$AK.A4",
      "A5" : "$AK.A5",
      "A6" : "$AK.A6",
      "A7" : "$AK.A7",
       "B" : "$BK"}
    },{
      $out : "referencing_B_in_A"
    }
  ],{allowDiskUse:true}
)
```

Referencing di B in A


```
"_id": 8518,
"AK": 8518,
"A1": 6773,
"A2": 253,
"A3": 4,
"A4": 6773,
"A5": 253,
"A6": 4,
"A7": "Lorem ipsum dolor sit amet, consectetur adipiscing elit.
  Fusce lacinia eget arcu et maximus. Ut tempus est sit amet
  tortor commodo, sit amet facilisis mi rhoncus. Donec et elit
  venenatis, consequat tellus eu, tristique orci. Duis
  tristique sem ut nulla ullamcorper, a porta risus efficitur.
  Cras sed neque et nisl tincidunt vestibulum. Phasellus
  tristique tempor facilisis. Sed facilisis lectus eros, sed
  aliquet lacus elementum sed. Integer vel dictum mi.
  Maecenas pharetra tempus eros, efficitur mattis erat cursus
  in. Nulla sit amet quam velit. Nullam tempus dictum lacus
  id porttitor. Vestibulum facilisis pulvinar fermentum.
```

```
  Ut elementum maximus feugiat. In at mollis leo, eu
  facilisis magna. Vestibulum sed nisi ultricies, tincidunt
  enim ac, fringilla ex. Phasellus pharetra mollis nisi
  a fermentum. In nec faucibus nulla, eget molestie magna.
  Vivamus in gravida ex. Aenean scelerisque gravida
  ipsum, nec congue enim posuere sit amet. Donec vitae felis
  id sem congue blandit eget non justo quis.",
"B": [
  182143,
  450648,
  120258,
  151670,
  314940,
  281717,
  335311,
  802016,
  313524,
  537
]
```

Referencing di B in A

Embedding

Per l'embedding di documenti si e' dovuto sempre eseguire dei join ma e' stato fondamentale poter aggiungere un intero documento all'interno di un'array tramite il parametro `$$ROOT` che ha permesso un operazione molto piu'veloce e compatta.

Embedding di A in B

```
db.B.aggregate(
  [
    {
      $lookup: {
        from: 'A',
        localField: 'FAK',
        foreignField: 'AK',
        as: 'A'
      }
    }
   ,{
```

```
    $project: {
      "FAK" : 0,
      "_id" : 0,
      "A._id" : 0
    }
  }
  ,{
    $project : {
      "_id" : "$BK",
      "B1" : 1,
      "B2" : 1,
      "B3" : 1,
      "B4" : 1,
      "B5" : 1,
      "B6" : 1,
      "B7" : 1,
      "A" : 1
    }
  }
  ,{
     $out : "embedding_A_in_B"
  }
  ]
)
```

Embedding di B in A

```
"_id": 963593,
"B1": 77221,
"B2": 86,
"B3": 1,
"B4": 77221,
"B5": 86,
"B6": 1,
"B7": [ ..... ],
"A": [
  {
    "AK": 70394,
    "A1": 7960,
    "A2": 269,
    "A3": 8,
```

```
    "A4": 7960,
    "A5": 269,
    "A6": 8,
    "A7": [ ..... ]
  }
]
```

Embedding di B in A

Embedding di B in A

```
    db.B.aggregate(
  [
   {
      $group: {
        _id: {"AK" : "$FAK"}, "BK": {$addToSet : "$$ROOT"}
      }
    },
    {
      $lookup: {
        from: 'A',
        localField: '_id.AK',
        foreignField: 'AK',
        as: 'AK'
      }
    },{
      $project : {"_id" : 0,"BK.FAK" : 0}
    },{
    $unwind: {
      path: "$AK",
    }},{
      $project : {
        "_id" : "$AK.AK",
        "AK" : "$AK.AK",
        "A1" : "$AK.A1",
        "A2" : "$AK.A2",
        "A3" : "$AK.A3",
        "A4" : "$AK.A4",
        "A5" : "$AK.A5",
        "A6" : "$AK.A6",
```

```
        "A7" : "$AK.A7",
        "B" : "$BK"}
    },{
        $project : { "A._id" : 0, "B._id" : 0}
    },{
        $out : "embedding_B_in_A"
   }
  ],{allowDiskUse:true}
)
```

Embedding di B in A


```
"_id": 48,
"AK": 48,
"A1": 691,
"A2": 154,
"A3": 0,
"A4": 691,
"A5": 154,
"A6": 0,
"A7": [ ..... ],
"B": [
  {
    "BK": 844575,
    "B1": 94813,
    "B2": 140,
    "B3": 2,
    "B4": 94813,
    "B5": 140,
    "B6": 2,
    "B7": [ ..... ]
  },
  {
    "BK": 115006,
    "B1": 36,
    "B2": 483,
    "B3": 8,
    "B4": 36,
    "B5": 483,
    "B6": 8,
    "B7": [ ..... ]
```

```
  },
  .
  .
  .
  .
  {
    "BK": 834226,
    "B1": 77768,
    "B2": 707,
    "B3": 6,
    "B4": 77768,
    "B5": 707,
    "B6": 6,
    "B7": [ ..... ]
  }
]
```

Embedding di B in A

2.2 Indici

Gli indici per gli attributi sono stati creati attraverso uno script in JS che viene eseguito durante la creazione del container.

MongoDB utilizza, se non esplicitamente indicato, come strutture dati per gli indici dei B-tree. Dato che e' stato scelto di adoperare l'embedding di interi documenti sono stati indicizzati anche gli attributi dei documenti innestati sui quali saranno esegeuite delle query, anche sulle foreign del referencing sono stati costruiti indici.

```
db.getCollection('embedding_A_in_B').createIndex({'B4': 1});
db.getCollection('embedding_A_in_B').createIndex({'B5': 1});
db.getCollection('embedding_A_in_B').createIndex({'B6': 1});


db.getCollection('embedding_A_in_B').createIndex({'A.A4': 1});
db.getCollection('embedding_A_in_B').createIndex({'A.A5': 1});
db.getCollection('embedding_A_in_B').createIndex({'A.A6': 1});


db.getCollection('embedding_B_in_A').createIndex({'B.B4': 1});
db.getCollection('embedding_B_in_A').createIndex({'B.B5': 1});
db.getCollection('embedding_B_in_A').createIndex({'B.B6': 1});

db.getCollection('embedding_B_in_A').createIndex({'A4': 1});
db.getCollection('embedding_B_in_A').createIndex({'A5': 1});
db.getCollection('embedding_B_in_A').createIndex({'A6': 1});

db.getCollection('referencing_A_in_B').createIndex({'AK': 1});

db.getCollection('referencing_A_in_B').createIndex({'B4': 1});
db.getCollection('referencing_A_in_B').createIndex({'B5': 1});
db.getCollection('referencing_A_in_B').createIndex({'B6': 1});

db.getCollection('referencing_B_in_A').createIndex({'AK': 1});

db.getCollection('referencing_B_in_A').createIndex({'A4': 1});
db.getCollection('referencing_B_in_A').createIndex({'A5': 1});
db.getCollection('referencing_B_in_A').createIndex({'A6': 1});


db.getCollection('embedding_A_in_B').createIndex({'A': 1});
db.getCollection('embedding_B_in_A').createIndex({'B': 1});
```

```
// indexes
db.getCollection('embedding_A_in_B').createIndex({'B4': 1});
db.getCollection('embedding_A_in_B').createIndex({'B5': 1});
db.getCollection('embedding_A_in_B').createIndex({'B6': 1});

// nested indexes
db.getCollection('embedding_A_in_B').createIndex({'A.A4': 1});
db.getCollection('embedding_A_in_B').createIndex({'A.A5': 1});
db.getCollection('embedding_A_in_B').createIndex({'A.A6': 1});

// indexes
db.getCollection('embedding_B_in_A').createIndex({'A4': 1});
db.getCollection('embedding_B_in_A').createIndex({'A5': 1});
db.getCollection('embedding_B_in_A').createIndex({'A6': 1});
```

```
15
16 // nested indexes
17 db.getCollection('embedding_B_in_A').createIndex({'B.B4': 1});
18 db.getCollection('embedding_B_in_A').createIndex({'B.B5': 1});
19 db.getCollection('embedding_B_in_A').createIndex({'B.B6': 1});
20
21 //FK
22 db.getCollection('referencing_A_in_B').createIndex({'AK': 1});
23
24 // indexes
25 db.getCollection('referencing_A_in_B').createIndex({'B4': 1});
26 db.getCollection('referencing_A_in_B').createIndex({'B5': 1});
27 db.getCollection('referencing_A_in_B').createIndex({'B6': 1});
28
29 //FK
30 db.getCollection('referencing_B_in_A').createIndex({'AK': 1});
31
32 // indexes
33 db.getCollection('referencing_B_in_A').createIndex({'A4': 1});
34 db.getCollection('referencing_B_in_A').createIndex({'A5': 1});
35 db.getCollection('referencing_B_in_A').createIndex({'A6': 1});
36
37 // array indexes
38 db.getCollection('embedding_A_in_B').createIndex({'A': 1});
39 db.getCollection('embedding_B_in_A').createIndex({'B': 1});
```

Listing 1: making indexes

Oracle

1 Introduzione

Oracle e' una societa' che mette a disposizione numerosi prodotti, per la parte di confronto relazionale e' stato usato oracle SQL developer, un software opensource che mette a disposizione un software per poter lavorare con SQL su database di Oracle attraverso il JDK (java development kit).

2 Raccolta dati

3 Organizzazione dei dati

Utilizzando un sistema relazionale ci si e' dovuti limitare alla crezione di due collezioni distinte A (Post) e B(Commenti) sulle quali eseguire le query di selezione per poter ottenere una stima dei costi su un modello relazionale che non utlizasse embedding e referencing.

Sono stati creati file .csv dei dati facilmente importabili in un database Oracle creato su un computer fisso, sui quali sono state effettuate alcune operazioni come la creazione di indici per specifici attributi e la limitazione della memoria cache del database locale.

```
␣Primary␣key␣per␣A

ter␣table␣"SYS"."A"␣add␣constraint␣PK␣primary␣key("AK")

␣Primary␣key␣per␣B

ter␣table␣"SYS"."B"␣add␣constraint␣PKB␣primary␣key("BK")

␣Aggiungere␣il␣constraint␣per␣FAK

TER␣TABLE␣B
ADD␣CONSTRAINT␣FK_A_constr␣FOREIGN␣KEY␣(FAK)
␣␣␣␣REFERENCES␣A(AK)
```

```
␣␣␣␣ON␣DELETE␣CASCADE;

␣Indici

EATE␣BITMAP␣INDEX␣A_A4_BITMAP␣ON␣A␣(A4␣ASC);
EATE␣BITMAP␣INDEX␣A_A5_BITMAP␣ON␣A␣(A5␣ASC);
EATE␣BITMAP␣INDEX␣A_A6_BITMAP␣ON␣A␣(A6␣ASC);
EATE␣BITMAP␣INDEX␣B_B4_BITMAP␣ON␣B␣(B4␣ASC);
EATE␣BITMAP␣INDEX␣B_B5_BITMAP␣ON␣B␣(B5␣ASC);
EATE␣BITMAP␣INDEX␣B_B6_BITMAP␣ON␣B␣(B6␣ASC);
EATE␣BITMAP␣INDEX␣B_FK_BITMAP␣ON␣B␣(FAK␣ASC);

␣Ridurre␣la␣cache␣del␣client␣di␣sistema

TER␣SYSTEM␣SET␣CLIENT_RESULT_CACHE_SIZE␣=␣128M␣SCOPE=SPFILE;
```

Per poter eseguire le query di selezione e' stato utilizzato uno script in python che utilizza il modulo `cx_Oracle` per poter creare una connessione al database locale ed effettuare un numero arbitrario di query, ogni query effettuata riporta un piano di esecuzione visionabile nell'apposito file .sql. Dopo che la connessione viene confermata, si procede a creare un cursore con il quale si andranno ad eseguire query articolate come segue:

```
␣␣␣␣␣␣EXPLAIN␣PLAN␣FOR␣\emph{SELECT␣*␣FROM␣A␣WHERE␣A6␣=␣612};
␣␣␣␣␣␣SELECT␣PLAN_TABLE_OUTPUT␣FROM␣TABLE(DBMS_XPLAN.DISPLAY());
```

Che provvedono ad esegure una query e scrivere una riga all'interno del `PLAN_TABLE_OUTPUT` che poi verra letta e salvata in un file, per poter avere una copia del piano di esecuzione di ciascuna query.

	A	B
A0	15	
A1	47	
A2	17	
A3	6	
A4	4	
A5	1	
A6	1	
B0		7
B1		295
B2		10
B3		5
B4		3
B5		5
B6		1
A0j	5	
A1j	15	
A2j	3	
A3j	4	
A4j	3	
A5j	2	
A6j	3	
B0j		4
B1j		524
B2j		10
B3j		937
B4j		2
B5j		5
B6j		797

CouchDb

1 Caratteristiche

E' un sistema di gestione di basi di dati non relazionali. E' stato creato soprattutto per il mondo Web, progettato per poter gestire sia importanti quantita' di richieste attraverso la rete sia per poter immagazzinare i dati in dispositivi mobili ed essere veloce. Utilizza una HTTP/JSON API per poter gestire le richieste ed inviare i dati, quindi fa ampio utilizzo di POST, PUT, DELETE e cosi via. E' diventato un progetto Apache nel 2008, versione OpenSource di CouchServer.

Per poter eseguire query su CouchDB si utilizza Mango, un linguaggio di interrogazione JSON, molto simile a Mongo ma con alcune differenze, tra le piu' importanti c'e' la mancanza dell'operatore di lookup ossia di join, infatti i tempi che presentero' successivamente sulle query di join sono sostanzialmente la somma di query di selezione sulle varie collezioni.

2 Popolamento

Per poter popolare i database contenti i diversi tipi di collezione si e' utilizzato le collezioni di documenti precedentemente create attraverso MongoDB e per ogni riga, ossia documento, attraverso una post all'indirizzo locale del server di CouchDB si e' potuta eseguire una query.

CouchDB richiede che il campo `_id` sia una stringa, quindi attraverso il comando sed in uno script in bash si e' potuto riutilizzare le collezione esportate da MongoDB, dato che il join non e' tra gli operatori di Mango, per generare nuovamente le collezioni.

```
t dataJSON/embedding_A_in_B.json  | sed -r 's/"_id":([0-9]+)/ "_id": "\1" /' >> dataC
t dataJSON/embedding_B_in_A.json |  sed -r 's/"_id":([0-9]+)/ "_id": "\1" /'  >> data
t dataJSON/referencing_A_in_B.json| sed -r 's/"_id":([0-9]+)/ "_id": "\1" /' >> dataC
t dataJSON/referencing_B_in_A.json| sed -r 's/"_id":([0-9]+)/ "_id": "\1" /' >> dataC
```

```
port␣requests
port␣json
```

```
l␣=␣"http://admin:admin@127.0.0.1:5984/b"

yload␣=␣json.dumps({
"_id":␣"738878",
"BK":␣738878,
"B1":␣94207,
"B2":␣176,
"B3":␣3,
"B4":␣94207,
"B5":␣176,
"B6":␣3,
"B7":␣"Lorem␣ipsum␣dolor␣sit␣amet,␣consectetur␣adipiscing␣elit.␣........␣"

aders␣=␣{
'Accept':␣'application/json',
'Content-Type':␣'application/json'


sponse␣=␣requests.request("POST",␣url,␣headers=headers,␣data=payload)

int(response.text)
```

3 Indici

Gli indici all'interno di ogni collezione sono stati creati tramite uno script in python con un procedimento simile, per poter ottenere collezioni uguali in tutto e per tutto a quelle di MongoDB. Mango e' un linguaggio di query dichiarativo JSON per CouchDB. Gli indici di Mango con tipo json, sono costruiti usando viste MapReduce attraverso il seguente script in python:

```
port␣requests
port␣json
port␣os

llections_a␣=␣[␣'referencing_b_in_a',␣'embedding_b_in_a']
llections_b␣=␣['embedding_a_in_b',␣␣'referencing_a_in_b']

d_a=␣["A4",␣␣"A5",␣"A6"]
d_b=␣["B4",␣␣"B5",␣"B6"]
```

```
A
l␣=␣"http://admin:admin@127.0.0.1:5984/a/_index?partitioned=true"
r␣ind␣␣in␣ind_a:
payload␣=␣json.dumps({
␣␣"index":␣{
␣␣␣␣"fields":␣[
␣␣␣␣␣␣ind
␣␣␣␣]
␣␣},
␣␣"name":␣ind␣+␣"-index",
␣␣"type":␣"json"
})
headers␣=␣{
␣␣'Content-Type':␣'application/json'
}

response␣=␣requests.request("POST",␣url,␣headers=headers,␣data=payload)

print(response.text)
yload␣=␣json.dumps({
"index":␣{
␣␣"fields":␣[
␣␣␣␣"AK"
␣␣]
},
"name":␣"AK"␣+␣"-index",
"type":␣"json"

aders␣=␣{
'Content-Type':␣'application/json'

sponse␣=␣requests.request("POST",␣url,␣headers=headers,␣data=payload)
int(response)

B
l␣=␣"http://admin:admin@127.0.0.1:5984/b/_index?partitioned=true"
r␣ind␣␣in␣ind_b:
payload␣=␣json.dumps({
␣␣"index":␣{
```

```
␣␣␣␣"fields":␣[
␣␣␣␣␣␣␣␣ind
␣␣␣␣]
␣␣},
␣␣"name":␣ind␣+␣"-index",
␣␣"type":␣"json"
})
headers␣=␣{
␣␣'Content-Type':␣'application/json'
}

response␣=␣requests.request("POST",␣url,␣headers=headers,␣data=payload)

print(response.text)
yload␣=␣json.dumps({
"index":␣{
␣␣"fields":␣[
␣␣␣␣"BK"
␣␣]
},
"name":␣"BK"␣+␣"-index",
"type":␣"json"

aders␣=␣{
'Content-Type':␣'application/json'

sponse␣=␣requests.request("POST",␣url,␣headers=headers,␣data=payload)
int(response)

r␣collection␣in␣collections_a:
␣␣url␣=␣"http://admin:admin@127.0.0.1:5984/"␣+␣collection␣+␣"/_index?partitioned=true
␣␣for␣ind␣␣in␣ind_a:
␣␣␣␣␣␣payload␣=␣json.dumps({
␣␣␣␣␣␣␣␣"index":␣{
␣␣␣␣␣␣␣␣␣␣"fields":␣[
␣␣␣␣␣␣␣␣␣␣␣␣ind
␣␣␣␣␣␣␣␣␣␣]
␣␣␣␣␣␣␣␣},
␣␣␣␣␣␣␣␣"name":␣ind␣+␣"-index",
```

```
␣␣␣␣␣␣␣␣"type":␣"json"
␣␣␣␣␣␣})
␣␣␣␣␣␣headers␣=␣{
␣␣␣␣␣␣␣␣'Content-Type':␣'application/json'
␣␣␣␣␣␣}

␣␣␣␣␣␣response␣=␣requests.request("POST",␣url,␣headers=headers,␣data=payload)

␣␣␣␣␣␣print(response.text)

r␣collection␣in␣collections_b:
␣␣url␣=␣"http://admin:admin@127.0.0.1:5984/"␣+␣collection␣+␣"/_index?partitioned=true
␣␣for␣ind␣␣in␣ind_b:
␣␣␣␣␣␣payload␣=␣json.dumps({
␣␣␣␣␣␣␣␣"index":␣{
␣␣␣␣␣␣␣␣␣␣"fields":␣[
␣␣␣␣␣␣␣␣␣␣␣␣ind
␣␣␣␣␣␣␣␣␣␣]
␣␣␣␣␣␣␣␣},
␣␣␣␣␣␣␣␣"name":␣ind␣+␣"-index",
␣␣␣␣␣␣␣␣"type":␣"json"
␣␣␣␣␣␣})
␣␣␣␣␣␣headers␣=␣{
␣␣␣␣␣␣␣␣'Content-Type':␣'application/json'
␣␣␣␣␣␣}

␣␣␣␣␣␣response␣=␣requests.request("POST",␣url,␣headers=headers,␣data=payload)

␣␣␣␣␣␣print(response.text)

l␣=␣"http://admin:admin@127.0.0.1:5984/referencing_a_in_b/_index?partitioned=true"
yload␣=␣json.dumps({
"index":␣{
␣␣"fields":␣[
␣␣␣␣"AK"
␣␣]
},
"name":␣"AK"␣+␣"-index",
"type":␣"json"
```

```
aders␣=␣{
'Content-Type':␣'application/json'


sponse␣=␣requests.request("POST",␣url,␣headers=headers,␣data=payload)

emb␣AB
l␣=␣"http://admin:admin@127.0.0.1:5984/embedding_a_in_b/_index?partitioned=true"
r␣ind␣in␣ind_a:
payload␣=␣json.dumps({
␣␣"index":␣{
␣␣␣␣"fields":␣[
␣␣␣␣␣␣"A."␣+␣ind
␣␣␣␣]
␣␣},
␣␣"name":␣"A."␣+␣ind␣+␣"-index",
␣␣"type":␣"json"
})
headers␣=␣{
␣␣'Content-Type':␣'application/json'
}
response␣=␣requests.request("POST",␣url,␣headers=headers,␣data=payload)
print(response.text)

emb␣BA
l␣=␣"http://admin:admin@127.0.0.1:5984/embedding_b_in_a/_index?partitioned=true"
r␣ind␣in␣ind_b:
payload␣=␣json.dumps({
␣␣"index":␣{
␣␣␣␣"fields":␣[
␣␣␣␣␣␣"B."␣+␣ind
␣␣␣␣]
␣␣},
␣␣"name":␣"B."␣+␣ind␣+␣"-index",
␣␣"type":␣"json"
})
headers␣=␣{
␣␣'Content-Type':␣'application/json'
```

```
}
response␣=␣requests.request("POST",␣url,␣headers=headers,␣data=payload)
print(response.text)

ref␣BA
l␣=␣"http://admin:admin@127.0.0.1:5984/referencing_b_in_a/_index?partitioned=true"
yload␣=␣json.dumps({
"index":␣{
␣␣"fields":␣[
␣␣␣␣"B"
␣␣]
},
"name":␣"B"␣+␣"-index",
"type":␣"json"

aders␣=␣{
'Content-Type':␣'application/json'

sponse␣=␣requests.request("POST",␣url,␣headers=headers,␣data=payload)
int(response.text)
```

Bibliografia

[1] J. Beal, D. Pianini e M. Viroli, «Aggregate Programming for the Internet of Things», *Computer*, vol. 48, n. 9, pp. 22–30, set. 2015, ISSN: 0018-9162. DOI: 10.1109/MC.2015.261.

[2] D. Pianini, J. Beal e M. Viroli, «Practical Aggregate Programming with Protelis», in *2nd IEEE International Workshops on Foundations and Applications of Self* Systems, FAS*W@SASO/ICCAC 2017, Tucson, AZ, USA, September 18-22, 2017*, 2017, pp. 391–392. DOI: 10.1109/FAS-W.2017.186.

Ringraziamenti